

产品需求文档（PRD）

企业级 AI Agent 网关平台 · v3.0

版本：v3.0

日期：2026-04-20

核心调整：基于 copilot-api / openclaw / cc-switch 三项目综合方案，纯 HTTP 直调 Copilot API，支持完整双向协议转换

范围：Provider 兼容模式，不含 Agent-Native

1. 产品概述

基于 **new-api 二次开发** 的企业级 AI 模型网关，通过 GitHub Token → Copilot Token Exchange 机制，将 GitHub Copilot 订阅下的全部模型（GPT、Claude、Gemini 等）以 **OpenAI 和 Anthropic 双协议** 对外透明提供，并叠加企业级 Seat 管理、多级限流和旁路审计。

放弃 Copilot SDK 的原因：

Copilot SDK 本质是封装本地 Language Server 子进程，适合桌面工具，new-api 是多用户服务端网关，纯 HTTP 直调方案更轻量、更稳定、更适合高并发多租户场景。

核心价值：

- 企业客户零改造：OpenAI 客户端（Cursor、Continue 等）直接换 Base URL；Anthropic 客户端（Claude Code）同样零改造
- 一个网关覆盖 Copilot 订阅下所有模型（GPT-4.1、Claude 4、Gemini 2.5 等）
- 统一采购 Copilot Seat，1:1 用户映射，防滥用防风控
- 全链路旁路审计，满足企业合规要求
- 海外单集群 Kubernetes 部署，运维简单

2. 用户角色与使用方式

2.1 用户角色

角色	主要诉求	入口
企业开发者	现有工具换个 Base URL 即可用	任意 OpenAI / Anthropic 兼容客户端
企业内部系统	API 接入，集成到 CI/CD 等	REST API
企业管理员	管理 Seat、查看用量、审计	Web 管理控制台
平台运营	管理 GitHub Token 池、计费	运营后台

2.2 最终用户使用方式

方式 A：OpenAI 兼容客户端（零改造）

Code block

```
1 Base URL: https://gateway.your-domain.com
2 API Key:  sk-{企业分配的用户 Key}
3 Model:    gpt-4.1 / claude-sonnet-4 / gemini-2.5-flash (任选)
```

适用：Cursor、Continue、OpenCode、任意 OpenAI SDK 项目。

方式 B：Anthropic 兼容客户端（零改造）

Code block

```
1 ANTHROPIC_BASE_URL=https://gateway.your-domain.com
```

适用：Claude Code、任意 Anthropic SDK 项目。

网关自动处理 Anthropic ↔ OpenAI 协议双向转换，用户无感知。

方式 C：直接 API 调用

Code block

```
1  # OpenAI 格式
2  POST /v1/chat/completions
3  Authorization: Bearer sk-user-key
4  {"model": "claude-sonnet-4", "messages": [...], "stream": true}
5
6  # Anthropic 格式
7  POST /v1/messages
8  Authorization: Bearer sk-user-key
9  {"model": "claude-sonnet-4", "messages": [...], "stream": true}
10
11 # Embedding
12 POST /v1/embeddings
13 Authorization: Bearer sk-user-key
14 {"model": "text-embedding-3-small", "input": "..."}

```

方式 D：Web 管理控制台（管理员）

- Seat 绑定管理（用户 ↔ GitHub Token）
- 实时用量仪表盘（Token 消耗、请求数、限流命中率）
- 审计日志查询
- API Key 管理

3. 对外接口清单

接口	方法	协议	说明
<code>/v1/chat/completions</code>	POST	OpenAI	所有模型透传（Claude 模型内部转换，对外仍是 OpenAI 格式）
<code>/v1/messages</code>	POST	Anthropic	完整 Anthropic 协议支持，内部转 OpenAI 再转回
<code>/v1/embeddings</code>	POST	OpenAI	Embedding 透传
<code>/v1/models</code>	GET	OpenAI	动态从 Copilot 拉取可用模型列表

4. 核心功能需求

4.1 GitHub Copilot 渠道接入

Token Exchange（最核心）：

- 用户 API Key → Seat 映射 → GitHub Token → Copilot Token（短期，约 1 小时有效）
- 按服务端返回的 `refresh_in` 字段**主动刷新**（提前 60 秒），而非被动等过期
- 两级缓存：进程内 sync.Map（单实例） + Redis（多实例共享）

动态 Base URL：

- 从 Copilot Token 的 `proxy-ep` 字段解析（`proxy.xxx.com` → `api.xxx.com`）
- 支持 individual / business / enterprise 三种账号类型 fallback

IDE Headers 注入：

每次请求注入完整的 Copilot IDE 标识头（共 10 个 Header），缺少任何一个可能导致 403 或行为异常。关键 Header 包括：

- `editor-version`：动态从 AUR 拉取最新 VSCode 版本（24h 缓存），无需手动维护

- `x-request-id`：每次请求生成唯一 UUID
- `X-Initiator`：根据消息历史动态判断 `user` / `agent`

协议路由：

请求来源	模型前缀	Copilot 端点	转换
<code>/v1/chat/completions</code>	全部	<code>/chat/completions</code>	透传（Claude 需模型名规范化）
<code>/v1/messages</code>	全部	<code>/chat/completions</code>	请求：Anthropic→OpenAI；响应：OpenAI→Anthropic
<code>/v1/embeddings</code>	全部	<code>/embeddings</code>	透传

模型名规范化：

Copilot 不支持带子版本号的 Claude 模型名（如 `claude-sonnet-4-20250514` / `claude-sonnet-4-5`），必须截断为 `claude-sonnet-4`。

4.2 Anthropic ↔ OpenAI 双向协议转换

这是本次集成与上一版本最大的升级，支持 Claude Code 等 Anthropic 客户端零改造接入。

请求转换（Anthropic → OpenAI）：

- `system` 字段提取（string / `TextBlock` 数组两种形式）
- `tool_result block` → `role: "tool"` （必须排在用户消息之前）
- `tool_use block` → `tool_calls[]`
- `thinking block` → 合并进 `content` 文本（OpenAI 无对应概念）
- `image block` → `image_url` `ContentPart`
- `tool_choice` 映射（`any` → `required`，`tool` → `function` 指定）
- `max_tokens` 动态填充（从模型 `capabilities` 读取，fallback 8192）

响应转换（OpenAI → Anthropic）：

- 文本 → `text` block
- `tool_calls` → `tool_use` block
- `finish_reason` 映射（`stop` → `end_turn`，`tool_calls` → `tool_use` 等）
- `usage` 字段映射（含 `cache_read_input_tokens`）

流式转换（OpenAI SSE → Anthropic SSE 事件序列）：

使用有状态状态机转换，维护 block 开关状态：

- 首 chunk → `message_start`
- text delta → `content_block_start` + `content_block_delta` (`text_delta`)
- `tool_calls` delta → `content_block_start` (`tool_use`) + `content_block_delta` (`input_json_delta`)
- `finish_reason` → `content_block_stop` + `message_delta` + `message_stop`

4.3 Seat 1:1 映射

- 一个企业用户（`tenant_id + user_id`）绑定唯一一个 GitHub Token（对应一个 Copilot Seat）
- DB 唯一约束 + 分布式锁防并发重复绑定
- GitHub Token 加密存储（AES-256-GCM + KMS）
- 管理员可通过控制台解绑 / 重新绑定

4.4 多级限流

- **单 Seat 并发**：默认 1-3 并发请求（可按租户配置），超限返回 429
- **单 Seat QPM**：防止 GitHub 风控（Token Exchange 频率）
- **全局并发**：整体防雪崩上限
- **Fail-open**：Redis 不可用时本地内存兜底（50% 容量）

4.5 旁路审计

- 异步写入，不阻塞主链路
- 记录：模型、Token 用量、响应状态、耗时、IP Hash（不记录请求内容）
- 存储：PostgreSQL 热数据（30 天）+ 对象存储冷归档

4.6 动态模型列表

- 从 Copilot `/models` 接口实时拉取（30 分钟缓存）
- 自动适配不同 GitHub Plan 的可用模型
- 内置 fallback 模型列表（网络不可用时使用）

5. 内置模型列表（Fallback）

Code block

- ```
1 GPT 系列: gpt-4.1, gpt-4.1-mini, gpt-4.1-nano, gpt-4o, gpt-4o-mini
2 o 系列: o3, o3-mini, o4-mini
3 Claude 系列: claude-opus-4, claude-opus-4-5, claude-sonnet-4, claude-sonnet-4-5, claude-haiku-4-5
4 Gemini 系列: gemini-2.5-pro, gemini-2.5-flash, gemini-2.0-flash
5 其他: xai/grok-3, xai/grok-3-mini, mistral-large, cohere-command-r-plus
```

## 6. 部署架构

Code block





7. 风险

| 风险                                 | 级别 | 应对                                        |
|------------------------------------|----|-------------------------------------------|
| Copilot Internal API 是非公开接口，随时可能变更 | P1 | 跟踪三个参考项目更新；Adaptor 单层隔离                   |
| IDE Headers 版本过时被拒（全量 403）         | P1 | 动态从 AUR 拉取版本；监控 403 错误率告警；版本号可配置化热更新      |
| 单账号并发过高触发 GitHub 风控                | P0 | 单 Seat QPM + 并发限流；多 Token 池分散压力           |
| GitHub Token 泄露                    | P0 | AES-256-GCM 加密 + KMS；Token 只在运行时解密，不出现在日志 |
| Copilot Seat 共享条款合规                | P0 | 提前与 GitHub 销售确认；严格 1:1 映射                 |
| new-api AGPL-3.0 许可证               | P1 | 内部部署通常满足合规；正式上线前法务确认                      |
| stream 状态机边缘 case                  | P2 | 充分测试 tool_use / thinking / 并发 chunk 场景    |